

# WMM

## Laboratorium 1 - Sygnały

Podczas wykonywania DFT za każdym razem dzielę przez  $N$ , a odwrotnej DFT mnożę przez  $N$ . Robię tak, żeby przyjąć konwencję stosowaną na wykładzie (w bibliotece `numpy` jest odmienna). Dzięki temu wszystkie wzory z wykładu mają tu zastosowanie.

1. Dane są dwa sygnały o okresie podstawowym  $N = 4$ :  $s_1 = \{2, 3, 1, 0\}$  i  $s_2 = \{0, 3, 1, 0\}$ .
  - a) Dla każdego sygnału wyznaczyć i wykreślić widmo amplitudowe i fazowe, obliczyć moc sygnału i sprawdzić słuszność twierdzenia Parsewala.
  - b) Sprawdzić słuszność twierdzenia o dyskretnej transformacji Fouriera splotu kołowego sygnałów  $s_1$  i  $s_2$ : wyznaczyć ręcznie splot kołowy sygnałów  $s_1$  i  $s_2$ , a następnie wyznaczyć ten splot ponownie za pomocą dyskretnej transformacji Fouriera.

```
from matplotlib import pyplot as plt
from matplotlib.gridspec import GridSpec
import numpy as np
```

```
N = 4
```

```
s1 = np.array([2, 3, 1, 0])
s2 = np.array([0, 3, 1, 0])
```

```
SIGNALS = [s1, s2]
SIGNAL_NAMES = ["$s_1$", "$s_2$"]
```

```
# 1 a)
```

```
for s, name in zip(SIGNALS, SIGNAL_NAMES):
    fig = plt.figure(figsize=(16, 8))
    fig.suptitle(f"{name}")
    gs = GridSpec(ncols=2, nrows=2, figure=fig)

    ax_s = fig.add_subplot(gs[0, :])
    ax_ampl = fig.add_subplot(gs[1, 0])
    ax_phase = fig.add_subplot(gs[1, 1])

    # wykres sygnału
    ax_s.stem(s)
    ax_s.set_title("próbki sygnału")
    ax_s.set_xlabel("$n$")
    ax_s.set_ylabel("$s[n]$")

    # DFT
    s_fft = np.fft.fft(s) / N

    # widma amplitudowe i fazowe
    s_amplitude_spectrum = np.abs(s_fft)
    s_phase_spectrum = np.angle(s_fft)

    # wykres widma amplitudowego
    ax_ampl.stem(s_amplitude_spectrum)
    ax_ampl.set_title("widmo amplitudowe")
```

```

ax_ampl.set_xlabel("$k$")
ax_ampl.set_ylabel("$|X[k]|$")

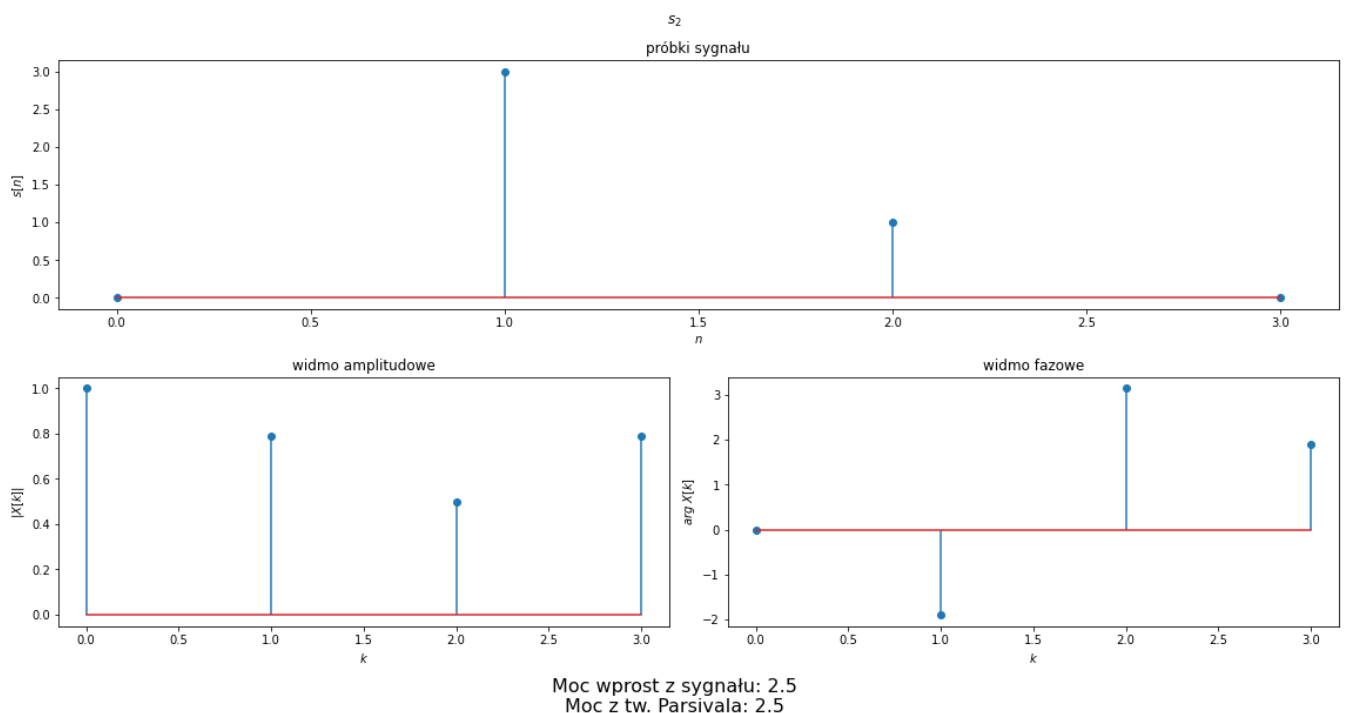
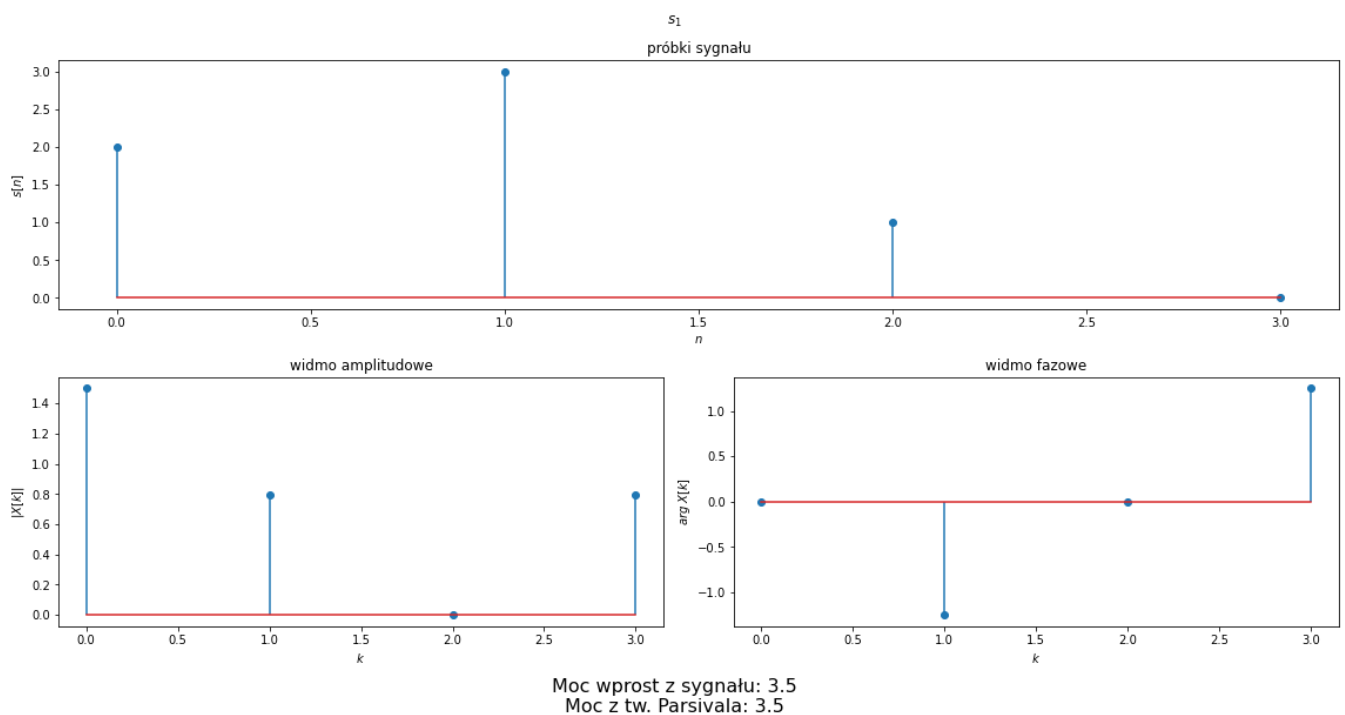
# wykres widma fazowego
ax_phase.stem(s_phase_spectrum)
ax_phase.set_title("widmo fazowe")
ax_phase.set_xlabel("$k$")
ax_phase.set_ylabel("$arg \; X[k]$")

# moc obliczona wprost z sygnału i moc obliczona z tw. Parsivala
power = np.mean(np.square(s))
power_parsival = np.sum(np.square(s_amplitude_spectrum))

bot_text = (f"Moc wprost z sygnału: {power}\n"
            f"Moc z tw. Parsivala: {power_parsival}")
fig.text(0.5, 0, bot_text, ha="center", va="top", fontsize=16)

fig.tight_layout()
plt.show()

```



Z twierdzenia o splocie cyklicznym:

$$\frac{1}{N}x_1[n] \circledast x_2[n] = X_1[n]X_2[n]$$

, zatem:

$$x_1[n] \circledast x_2[n] = X_1[n]X_2[n] \cdot N$$

```
# 1) b

def circular_convolve(x1: np.ndarray, x2: np.ndarray):
    N = len(x1)
    convolution = [0] * N
    for n in range(N):
        for m in range(len(x1)):
            m2 = (n - m) % N
            convolution[n] += x1[m] * x2[m2]
    return np.array(convolution)

fig, (ax1, ax2) = plt.subplots(1, 2)
fig.suptitle("splot $s_1$ \circledast $s_2$")
fig.set_size_inches(16, 6)

# splot obliczony wprost z definicji
convolution = circular_convolve(s1, s2)


ax1.stem(convolution)
ax1.set_title("wyznaczony z definicji")

# splot obliczony z twierdzenia o splocie cyklicznym
s1_fft = np.fft.fft(s1) / N
s2_fft = np.fft.fft(s2) / N
s_ifft = np.fft.ifft(s1_fft * s2_fft * N) * N
convolution_from_fft = np.real(s_ifft)

ax2.stem(convolution_from_fft)
ax2.set_title("wyznaczony z tw. o splocie w cyklicznym DFT")

for ax in [ax1, ax2]:
    ax.set_xlabel("$n$")
    ax.set_ylabel("$s_1[n] \circledast s_2[n]$")

fig.tight_layout()
plt.show()
```



2. Zbadać wpływ przesunięcia w czasie na postać widma amplitudowego i widma fazowego dyskretnego sygnału harmonicznego  $s[n] = A \sin\left(2\pi \frac{n}{N}\right)$  o amplitudzie  $A = 2$  i okresie podstawowym  $N = 88$ . W tym celu dla każdej wartości  $n_0 \in \left\{0, \frac{N}{4}, \frac{N}{2}, \frac{3N}{4}\right\}$  wykreślić widmo amplitudowe i fazowe przesuniętego sygnału  $s[n - n_0]$ . Skomentować otrzymane wyniki.

```
from matplotlib import pyplot as plt
from matplotlib.gridspec import GridSpec
import numpy as np

N = 88
A = 2
SHIFTS = np.arange(4) * N // 4
A_THRESHOLD = 1e-6

for shift in SHIFTS:
    fig = plt.figure(figsize=(16, 10))
    fig.suptitle(f"sygnał przesunięty o  $n_0={shift}$ ")
    gs = GridSpec(ncols=2, nrows=2, figure=fig)

    ax_s = fig.add_subplot(gs[0, :])
    ax_ampl = fig.add_subplot(gs[1, 0])
    ax_phase = fig.add_subplot(gs[1, 1])

    s = A * np.sin(2 * np.pi * (np.arange(N) - shift) / N)
    ax_s.stem(s)
    ax_s.set_title("próbki sygnału")
    ax_s.set_xlabel("$n$")
    ax_s.set_ylabel("$s[n]$")

    s_fft = np.fft.fft(s) / N
    s_amplitude_spc = np.abs(s_fft)

    # odfiltrowanie (wyzerowanie) składowych widma
    # o nieznaczco małej amplitudzie, aby na wykresie
    # widma fazowego widniały jedynie wartości odpowiadające
    # znaczącym składowym
    significance_mask = s_amplitude_spc <= A_THRESHOLD
    s_amplitude_spc[significance_mask] = 0
    s_fft[significance_mask] = 0

    s_phase_spc = np.angle(s_fft)

    ax_ampl.stem(s_amplitude_spc)
    ax_ampl.set_title("widmo amplitudowe")
    ax_phase.stem(s_phase_spc)
    ax_ampl.set_xlabel("$k$")
    ax_ampl.set_ylabel("$|X[k]|$")

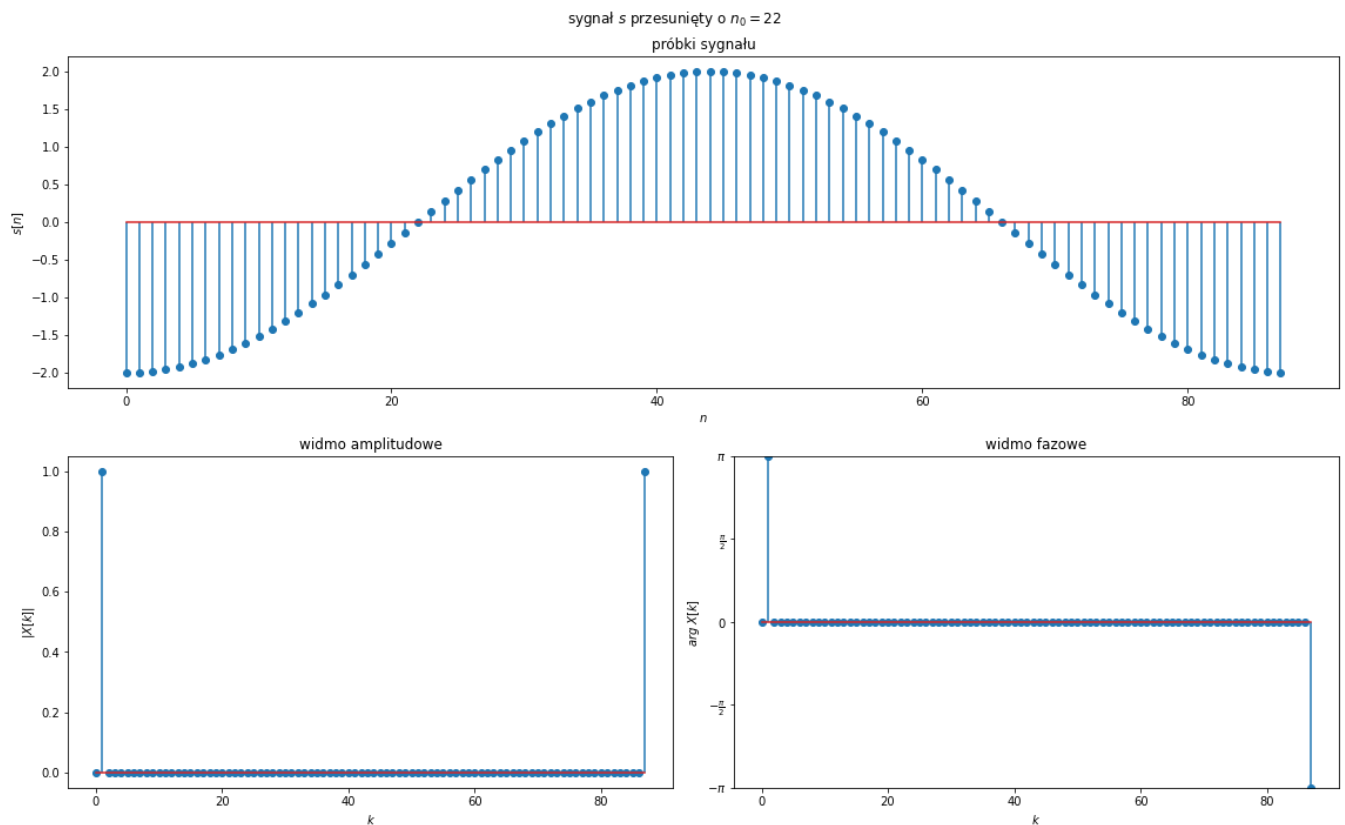
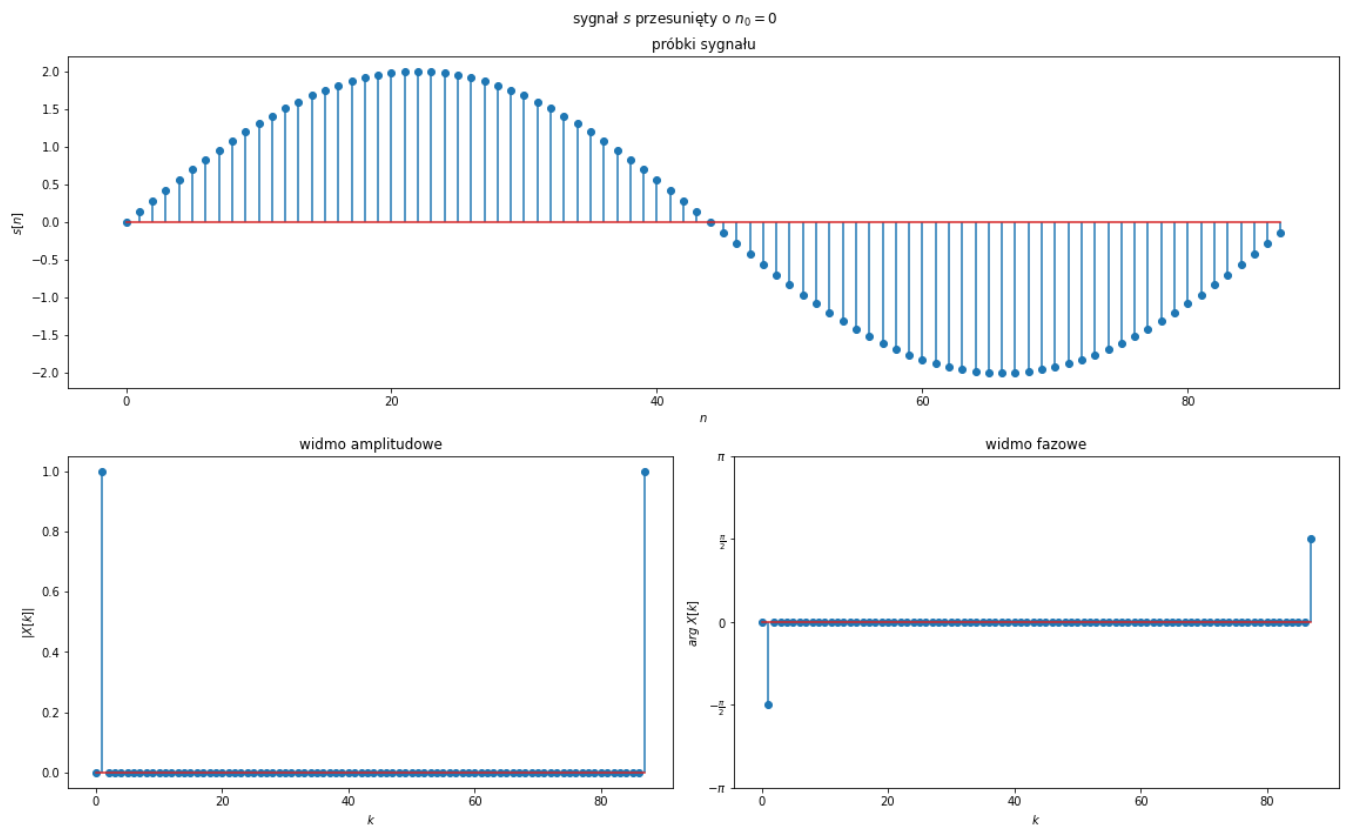
    ax_phase.set_title("widmo fazowe")
    ax_phase.set_ylim((-np.pi, np.pi))
    ax_phase.set_xlabel("$k$")
    ax_phase.set_ylabel("$arg \\; X[k]$")
    yticks = [
        (-np.pi, '$-\\pi$'),
        (-np.pi / 2, '$-\\frac{\\pi}{2}$'),
        (0, '$0$'),
        (np.pi / 2, '$\\frac{\\pi}{2}$'),
        (np.pi, '$\\pi$')
    ]
```

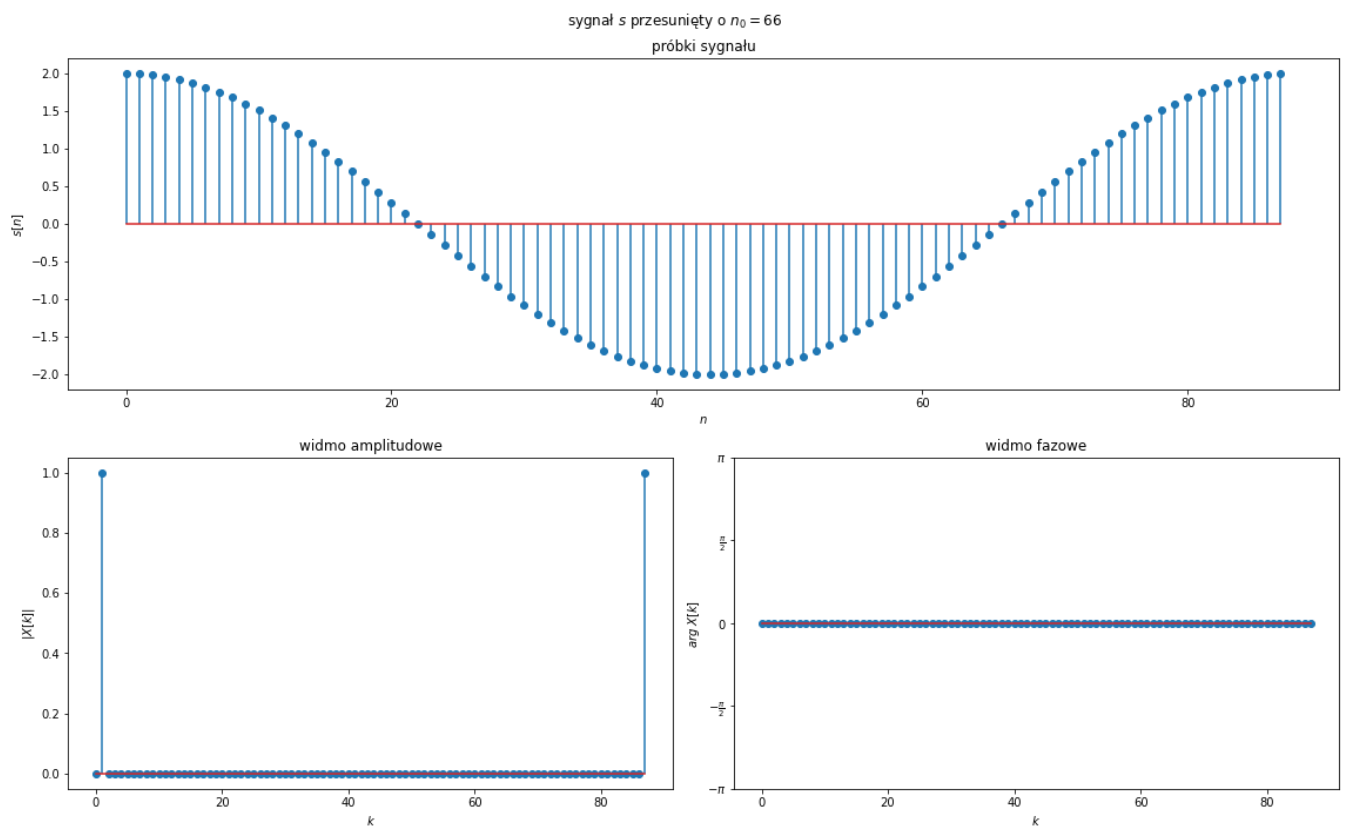
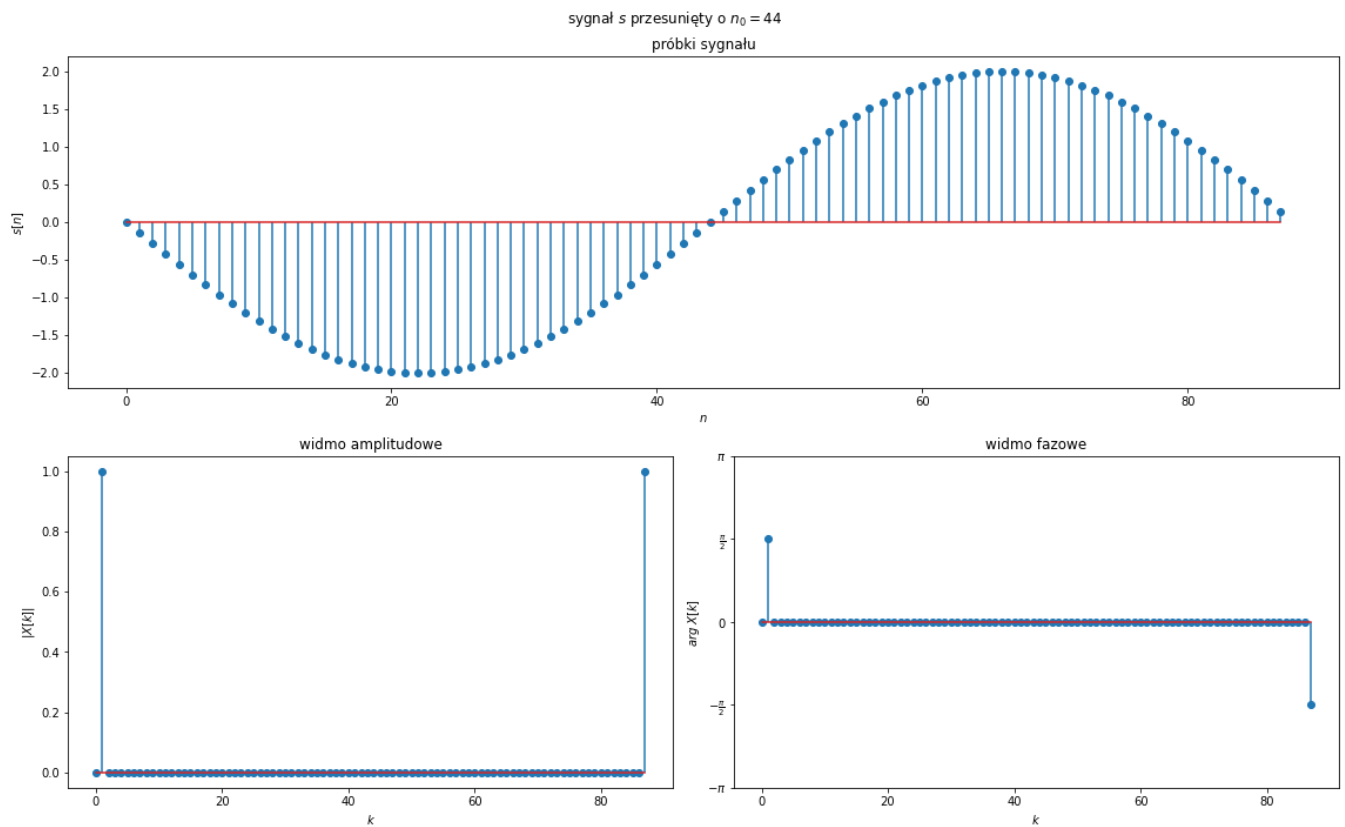
```

(np.pi, '$\\pi$')
]
ax_phase.set_yticks([t for t, _ in yticks])
ax_phase.set_yticklabels([l for _, l in yticks])

fig.tight_layout()
plt.show()
plt.close()

```





Obserwacje:

- dla każdego przesunięcia widmo amplitudowe jest takie samo
- dla każdego kolejnego przesunięcia sygnału o  $\frac{N}{4}$  zmienia się widmo fazowe:
  - $X[1]$  zmniejszane jest o  $\frac{\pi}{2}$
  - $X[N - 1]$  zwiększane jest o  $\frac{\pi}{2}$

Wynika to właściwości przesunięcia w dziedzinie czasu DFT

$$x[n - n_0] \leftrightarrow X[k]e^{-j\frac{2\pi}{N}kn_0}$$

W naszym przypadku:

$$x[n - 22] \leftrightarrow X[k]e^{-j\frac{\pi}{2}k}$$

$$x[n - 44] \leftrightarrow X[k]e^{-j\pi k}$$

$$x[n - 66] \leftrightarrow X[k]e^{-j\frac{3\pi}{2}k}$$

Po podstawieniu  $k = 1$  lub  $k = -1$  wyjdą zaobserwowane zmiany w widmie.

3. Zbadać wpływ dopełnienia zerami na postać widma amplitudowego i widma fazowego dyskretnego sygnału  $s[n] = A \left( 1 - \frac{n \bmod N}{N} \right)$  o amplitudzie  $A = 4$  i okresie podstawowym  $N = 12$ . W tym celu dla każdej wartości  $N_0 \in \{0, 1N, 4N, 9N\}$  wykreślić widmo amplitudowe i fazowe sygnału  $s[n]$  dopełnionego  $N_0$  zerami. Skomentować otrzymane wyniki.

```
from matplotlib import pyplot as plt
from matplotlib.gridspec import GridSpec
import numpy as np

N = 12
A = 4
N0 = np.square(np.arange(4)) * N

s0 = A * (1 - (np.arange(N) % N) / N)

for n0 in N0:
    fig = plt.figure(figsize=(16, 8))
    fig.suptitle(f"sygnał $$ dopełniony o $n_0={n0}$ zer")
    gs = GridSpec(ncols=2, nrows=2, figure=fig)

    ax_s = fig.add_subplot(gs[0, :])
    ax_ampl = fig.add_subplot(gs[1, 0])
    ax_phase = fig.add_subplot(gs[1, 1])

    s = np.concatenate((s0, np.zeros(n0)))

    ax_s.stem(s)
    ax_s.set_title("próbki sygnału")
    ax_s.set_xlabel("$n$")
    ax_s.set_ylabel("$s[n]$")

    s_fft = np.fft.fft(s) / N
    s_amplitude_spectrum = np.abs(s_fft)
    s_phase_spectrum = np.angle(s_fft)

    ax_ampl.stem(s_amplitude_spectrum)
    ax_ampl.set_title("widmo amplitudowe")
    ax_ampl.set_xlabel("$k$")
    ax_ampl.set_ylabel("$|X[k]|$")


    ax_phase.stem(s_phase_spectrum)
    ax_phase.set_title("widmo fazowe")
    ax_phase.set_xlabel("$k$")
    ax_phase.set_ylabel("$arg \\; X[k]$")
    ax_phase.set_ylim((-np.pi, np.pi))

    fig.tight_layout()
    plt.show()
    plt.close()
```




sygnał  $s$  dopełniony o  $n_0 = 0$  zer


próbki sygnału



widmo amplitudowe




widmo fazowe




sygnał  $s$  dopełniony o  $n_0 = 12$  zer


próbki sygnału



widmo amplitudowe




widmo fazowe




sygnał  $s$  dopełniony o  $n_0 = 48$  zer


próbki sygnału

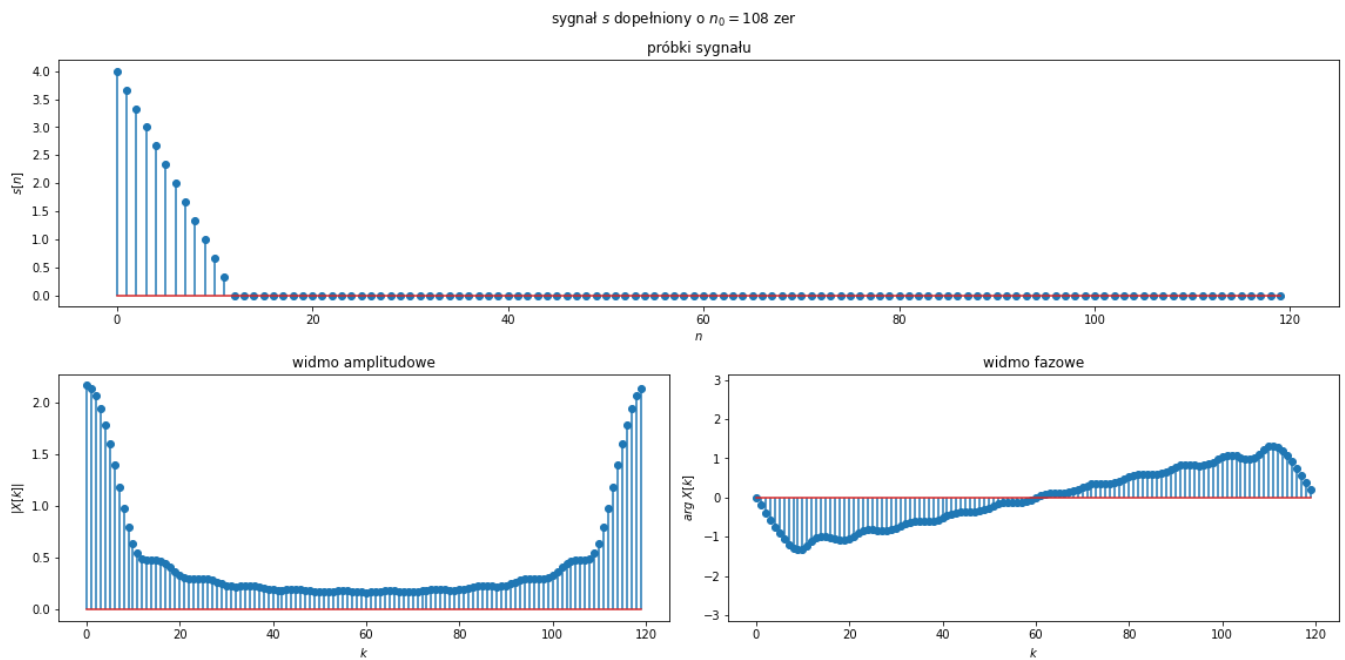


widmo amplitudowe



widmo fazowe





Obserwacje:

- dopełnienie sygnału zerami nie zmienia ogólnego kształtu obu widm, a jedynie zwiększa rozdzielczość w dziedzinie częstotliwości, dodając wartości pośrednie

Zachowanie to wynika ze wzoru na odległość między kolejnymi wyrazami DFT:

$$\Delta f_N = \frac{f_s}{N}$$

Jak widać można ją zmniejszyć poprzez zwiększenie ilości próbek.

4. Dany jest sygnał rzeczywisty  $s(t) = A_1 \sin(2\pi f_1 t) + A_2 \sin(2\pi f_2 t) + A_3 \sin(2\pi f_3 t)$ , gdzie  $A_1 = 0.1$ ,  $f_1 = 3000$  Hz,  $A_2 = 0.7$ ,  $f_2 = 8000$  Hz,  $A_3 = 0.9$ ,  $f_3 = 11000$  Hz. Przy założeniu, że liczba próbek sygnału wynosi  $N_1 = 2048$ , przedstawić wykres widmowej gęstości mocy sygnału  $s(t)$ . Czy dla podanej liczby próbek mamy do czynienia ze zjawiskiem przecieku widma? Czy sytuacja uległaby zmianie dla liczby próbek  $N_2 = \frac{3}{2} N_1$ ? Odpowiedź uzasadnić.

*# zgodnie z zaleceniami przyjmuję częstotliwość próbkowania 48 kHz*

```
from matplotlib import pyplot as plt
from matplotlib.gridspec import GridSpec
import numpy as np
from typing import Iterable
```

```
N = 2048
```

```
SAMPLE_FREQUENCY = 48_000
```

```
COMPONENT_AMPLITUDES = [0.1, 0.7, 0.9]
```

```
COMPONENT_FREQUENCIES = [3e3, 8e3, 11e3]
```

```
A_THRESHOLD = 1e-6
```

```
def sin_samples(amplitude: float, frequency: float,
                n_samples: int, sample_frequency: float):
    time_samples = 1 / sample_frequency * np.arange(n_samples)
    return amplitude * np.sin(2 * np.pi * frequency * time_samples)
```

```
def sin_sum_samples(amplitudes: Iterable[float], frequencies: Iterable[float],
                    n_samples: int, sample_frequency: float):
    return sum(
        sin_samples(amplitude, frequency, n_samples, sample_frequency)
        for amplitude, frequency in zip(amplitudes, frequencies)
    )
```

```
def plot(signal: np.ndarray):
    fig, (ax_1, ax_2) = plt.subplots(2, 1)
    fig.set_size_inches((16, 8))
    fig.suptitle(f"sygnał {signal}")

    ax_1.plot(signal[:100])
    ax_1.set_title("próbki sygnału (pierwsze 100)")
```

```
s_fft = np.fft.fft(signal) / N
```

*# odfiltrowanie (usunięcie) składowych widma amplitudowego tak,  
# aby wykresy były bardziej przejrzyste*

```
s_amplitude_spc = np.abs(s_fft)
significance_mask = s_amplitude_spc > A_THRESHOLD
s_amplitude_spc_filtered = s_amplitude_spc[significance_mask]
x = np.arange(len(s_amplitude_spc))[significance_mask]
```

```
s_power_spc = s_amplitude_spc_filtered ** 2
```


```
ax_2.stem(x, s_power_spc)
ax_2.set_title("widmowa gęstość mocy")
ax_2.set_xlim((0, ax_2.get_xlim()[1]))
```

```
fig.tight_layout()
```

```
plt.show()
plt.close()
```

```
s = sin_sum_samples(COMPONENT_AMPLITUDES, COMPONENT_FREQUENCIES,
                    N, SAMPLE_FREQUENCY)
```

```
plot(s)
```



Obserwacje:

- widać efekt zjawiska przecieku widma
- pomimo zastosowania filtracji składowych widma o małej amplitudzie, prawie każda składowa jest widoczna na wykresie

Efekt ten wynika z tego, że nie wszystkie składowe częstotliwości sygnału są podzielne przez rozdzielczość dyskretyzacji częstotliwości transformaty DFT.

$$\Delta f = \frac{f_s}{N} = \frac{48000}{2048} = 23.4375$$

$$\frac{f_1}{\Delta f} = 128$$

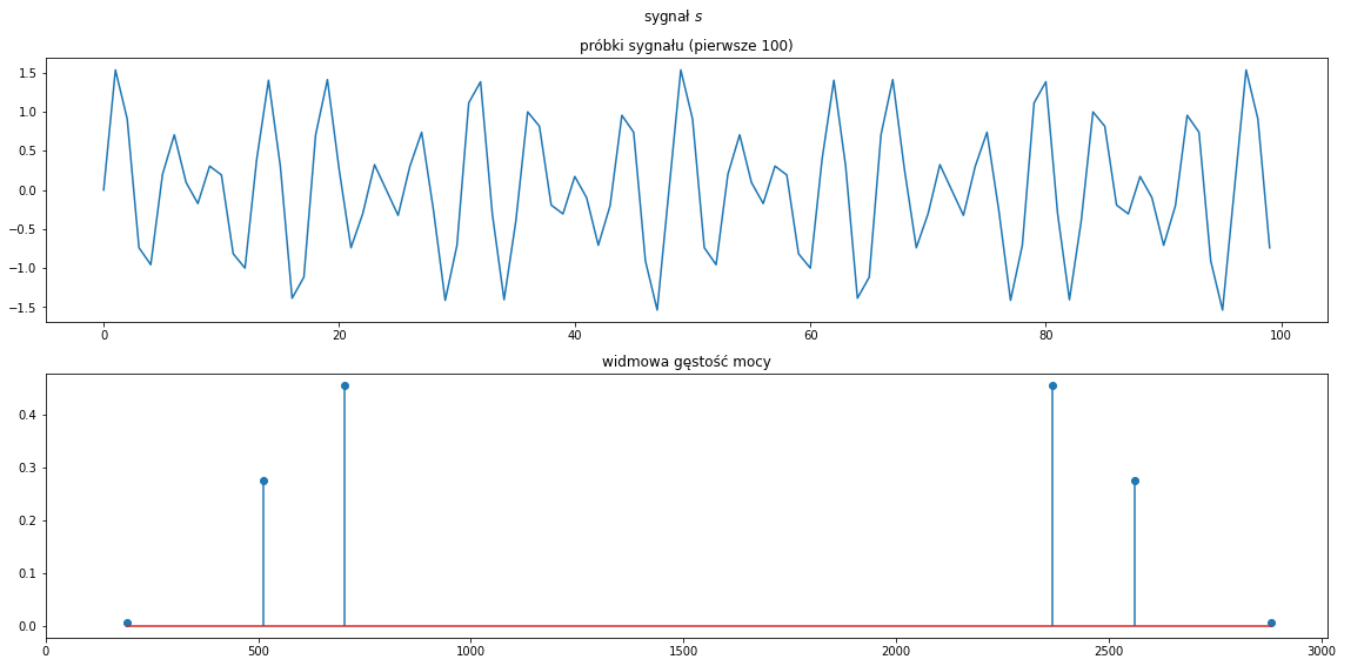
$$\frac{f_2}{\Delta f} = 341 \frac{1}{3}$$

$$\frac{f_3}{\Delta f} = 369 \frac{1}{3}$$

Jak widać częstotliwości  $f_2$  i  $f_3$  nie dzielą się przez  $\Delta f$ . Oznacza to że nie można ich zareprezentować w dokładny sposób stosując taką dyskretyzację częstotliwości.

```
s = sin_sum_samples(COMPONENT_AMPLITUDES, COMPONENT_FREQUENCIES,
                    3 / 2 * N, SAMPLE_FREQUENCY)
```

```
plot(s)
```



Obserwacje:

- tym razem widać tylko 3 prążki - dokładnie tyle ile składowych częstotliwości w sygnale
- w związku z tym nie ma efektu przecieku widma

Różnica w stosunku do poprzedniego przykładu jest w tym, że tym razem częstotliwości składowe sygnału dzielą się przez rozdzielczość dyskretyzacji częstotliwości transformaty DFT.

$$\Delta f = \frac{f_s}{\frac{3}{2}N} = \frac{48000}{3072} = 15.625$$

$$\frac{f_1}{\Delta f} = 192$$

$$\frac{f_2}{\Delta f} = 512$$

$$\frac{f_3}{\Delta f} = 704$$

Częstotliwości te dokładnie odpowiadają wartościom  $k$ , dla których prążki na wykresie widmowej gęstości mocy są widoczne.